

Projeto: Avaliação de Desempenho de Bancos de Dados

Prazo para a definição do grupo: 12/04/2026

Prazo para a entrega do projeto: ~~17/05/2026~~ **24/05/2026**

1 Descrição Geral do Projeto

Neste projeto, a tarefa será fazer um estudo para medir e comparar o desempenho dos SGBDs PostgreSQL e MySQL/MariaDB na execução de diversos tipos de consultas e operações de modificação dos dados em SQL sobre um banco de dados relacional, com e sem o apoio de índices. No final do projeto, o grupo deverá entregar:

- um relatório descrevendo o estudo realizado e os seus resultados;
- um link para um repositório online com os códigos-fonte para a execução dos experimentos, arquivos com os resultados das medições de desempenho realizadas, geração dos gráficos, etc.
- ~~slides para uma apresentação do trabalho para a turma. A apresentação ocorrerá na aula do dia 19/05/26 e deverá durar no máximo 7 minutos.~~
- **um link do vídeo de apresentação do trabalho (com participação do grupo todo). O vídeo deve ter duração máxima de 10 minutos.**
- **os slides ou outros materiais usados na apresentação.**

O banco de dados que será usado no projeto é um recorte do banco de dados do site Stack Overflow (<https://stackoverflow.com/>) de 2010. A estrutura desse banco de dados e as instruções para baixá-lo e criá-lo no PostgreSQL e no MySQL/MariaDB são apresentadas na Seção 5.

2 Experimentos de Avaliação de Desempenho

Para os experimentos de avaliação de desempenho, o grupo deverá especificar um conjunto de operações e consultas sobre o BD do StackOverflow e escrevê-las em SQL.

As operações a serem avaliadas deverão incluir:

- Operações de inserção, remoção e alteração de registros em diferentes tabelas
- Buscas de registros pelo seu atributo chave-primária, tanto na busca de uma única chave quanto na busca de uma faixa de chaves

- Buscas de registros por diferentes tipos de atributos não-chave primária, inclusive com condições de seleção compostas
- Buscas de registros por meio de padrões de strings (usando o operador LIKE)
- Buscas envolvendo relacionamentos (junções e junções de junções)
- Buscas envolvendo subconsultas
- Buscas envolvendo operações de agrupamento e agregações (ex.: soma, média, mínimo, máximo, contagem)

O grupo precisará projetar experimentos para avaliar o desempenho das consultas em diferentes cenários de execução. Um cenário que deve existir é o do BD sem índices. Outros cenários devem ser derivados a partir da criação de índices sobre diferentes atributos e de diferentes tipos (como Árvore B+ e Hash). O grupo deverá identificar quais índices podem beneficiar mais as operações dos experimentos.

Cada cenário terá os seus resultados de desempenho e é a comparação desses resultados que deve ser analisada no estudo. Cada consulta definida precisará ser executada diversas vezes em cada cenário, pois o tempo de execução dela pode variar de uma execução para outra (devido a motivos diversos, tais como carga na máquina no momento da execução, paginação do SO e cache do SGBD/SO). Na execução, tente evitar tanto quanto possível que fatores externos (como outros programas em execução na máquina) interfiram nos resultados dos experimentos.

Escreva programas/scripts para submeter as operações aos SGBDs e coletar os respectivos tempos de execução. Para cada SGBD e cada cenário, execute cada operação pelo menos 20 vezes. Todos os experimentos deverão ser executados numa mesma máquina, caso contrário, seus resultados não serão comparáveis.

3 Relatório com os Resultados do Projeto

O relatório deve descrever as consultas definidas, os experimentos e cenários projetados, o ambiente computacional usado na execução (que inclui configurações da máquina e dos softwares dos SGBDs), as medidas de desempenho coletadas das execuções e as conclusões a que se chega a partir dos resultados.

É obrigatório na escrita do relatório o uso gráficos e tabelas feitas pelo grupo para mostrar e comparar o desempenho das operações. Para cada operação e SGBD, apresente o tempo médio de execução da operação e medidas variabilidade/dispersão (ex.: desvio padrão ou intervalo de confiança). Adicionalmente, recomenda-se apresentar todos os tempos das execuções de uma operação como um gráfico de linha (com o tempo no eixo y e o número da execução no eixo x) ou um diagrama de caixa (*boxplot*), possibilitando a visualização completa dos resultados obtidos.

A métrica de desempenho que deve ser obrigatoriamente avaliada nos experimentos é o tempo de execução das operações. Mas outras métricas de desempenho também podem ser consideradas pelo grupo, tais como uso de espaço em disco, o uso de memória RAM e ocupação da CPU.

O seguinte modelo sugere uma organização para o relatório, mas ela não é obrigatória. O importante é que o relatório contenha todos os itens listados acima:

https://docs.google.com/document/d/103J_NG71ZcUTQv5MeUEvc3gpd8K1xISBuikDWG58_tw/edit?usp=sharing

Inclua citações e referências bibliográficas no texto, para indicar as fontes usadas como base para o estudo realizado. É importante destacar que as referências devem ser utilizadas apenas para auxiliar

o desenvolvimento do estudo e a escrita. Conteúdo copiado sem a devida referência será considerado plágio.

4 Entrega

O relatório, os slides e o link da apresentação e o link para o repositório do projeto deverão ser entregues até às 23:59 do dia 17/05/2026 **24/05/2026**.

Avisos importantes:

- No README do repositório de código do projeto, deve haver instruções para a execução dos scripts/programas criados.
- Os códigos e as instruções disponibilizados devem possibilitar a reprodução do estudo realizado. Na avaliação da entrega, os experimentos serão reexecutados.
- Não deixe o repositório de código do projeto aberto para acesso de qualquer pessoa. Infelizmente, tivemos ocorrências de alunos que plagiaram trabalhos obtidos de repositórios abertos. Na entrega do projeto, conceda acesso para a profa Kelly e o monitor Wagner ao repositório fechado do grupo (contas associadas aos e-mails `kellyrb@ime.usp.br` e `wlancetti@gmail.com`).

5 Banco de Dados para os Experimentos

5.1 Como criar o Banco de Dados em seu Computador

Primeiro você precisará instalar o PostgreSQL e o MySQL/MariaDB em seu computador e configurar a senha dos seus usuários administradores, que são o *postgres* e o *root*, respectivamente. É importante configurar a senha para esses usuários, pois você precisará dela para estabelecer a conexão com o servidor e criar o BD para o projeto.

5.1.1 MySQL/MariaDB

Faça o download do script `mysql_script_criacao_bd.sql` e depois execute num terminal os comandos a seguir. O primeiro deles cria na instalação local do MySQL/MariaDB um BD chamado “StackOverflow”, enquanto o segundo executa o script que insere os dados no banco criado.

```
mysqladmin -u root -p create StackOverflow
mysql -u root -p StackOverflow < mysql_script_criacao_bd.sql
```

Nos comandos acima, usa-se o usuário `root` do MySQL para fazer a conexão com o SGBD. Mas você pode substituí-lo por outro usuário previamente criado no MySQL que tenha a permissão para criar BDs.

5.1.2 PostgreSQL

Faça o download do script `postgresql_script_criacao_bd.sql` e depois execute num terminal os comandos a seguir. O primeiro deles cria na instalação local do PostgreSQL um BD chamado “StackOverflow”, enquanto o segundo executa o script que insere os dados no banco criado.


```
psql -h localhost -U postgres -W -f postgresql_script_criacao_bd.sql
```

No comando acima, usa-se o usuário `postgres` do PostgreSQL para fazer a conexão com o SGBD. Mas você pode substituí-lo por outro usuário previamente criado no PostgreSQL e que tenha a permissão para criar BDs.

Diferentemente do que foi feito para o MySQL, no caso do PostgreSQL não é preciso criar o BD antes de executar o script. O próprio script faz a criação do BD antes de iniciar a carga dos dados.

5.2 Estrutura do Banco de Dados

A figura abaixo mostra o esquema relacional do banco de dados do projeto. Os atributos marcados com um ícone de chavinha amarela são chaves primárias das suas respectivas tabelas. Atributos com o ícone de losango vermelho são chaves estrangeiras. As linhas mostram os relacionamentos entre as tabelas, estabelecidos por meio das chaves estrangeiras. A descrição e outras informações sobre os atributos podem ser vistas no Anexo, no final deste documento.



5.3 Sobre os Dados

Os dados disponibilizados para o projeto por meio dos scripts de criação de banco de dados mencionados nesta seção foram gerados a partir da adaptação de um banco de dados MS SQL Server publicado em:

<https://www.brentozar.com/archive/2021/03/download-the-current-stack-overfl>

Assim como os dados originais de onde foram extraídos, esses dados estão compartilhados sob a licença cc-by-sa 3.0:

<http://creativecommons.org/licenses/by-sa/3.0/>

Você é livre para compartilhar o banco de dados e adaptá-lo para qualquer finalidade, contanto que credite os seus autores originais:

<https://archive.org/details/stackexchange>.

5.4 Dicas e Observações

- Tanto no PostgreSQL quanto no MySQL/MariDB, o BD StackOverflow está configurado como “case-sensitive” para os nomes dos atributos e tabelas. Portanto, na escrita dos comandos em SQL, atenção às letras maiúsculas e minúsculas nos nomes. Além disso, no PostgreSQL, os nomes das tabelas e atributos deverão ser grafados entre aspas nos comandos em SQL (pois o PostgreSQL converte os nomes sem aspas para minúsculo).
- Considere a criação de índices específicos para atributos textuais (principalmente os que armazenam textos longos, como é o caso de Post.Body e User.AboutMe, por exemplo). Esses índices indexam as palavras dentro do texto, para permitir busca eficiente por meio de palavras-chaves. Veja a documentação dos SGBDs para saber mais detalhes:

- <https://dev.mysql.com/doc/refman/9.6/en/innodb-fulltext-index.html>

- <https://www.postgresql.org/docs/current/textsearch-indexes.html>

Inclua nos experimentos consultas que se beneficiem desse tipo de índice.

- Na seguinte página, você encontra alguns exemplos de consultas sobre o BD do Stack Overflow. Entretanto, as consultas estão escritas para a versão completa da estrutura do BD (e, possivelmente, para uma versão mais recente dela). Além disso, as consultas estão com a sintaxe do SQL do MS SQL Server. De qualquer forma, esses exemplos podem trazer algumas ideias para as consultas dos seus experimentos:

<https://data.stackexchange.com/stackoverflow/queries>

A descrição da estrutura do BD original completo pode ser vista em:

<https://meta.stackexchange.com/questions/2677/database-schema-documentation>

Um diagrama dessa estrutura pode ser visto em:

<https://meta.stackexchange.com/questions/2677/database-schema-documentation/326361#326361>

Anexo – Descrição dos Atributos do Banco de Dados

Tabela *Users*

- *Id*: identificação do usuário
- *Reputation*: reputação do usuário (<https://stackoverflow.com/help/whats-reputation>)
- *CreationDate*: data de criação
- *DisplayName*: nome para exibição
- *LastAccessDate*: data e horário da última vez que o usuário carregou uma página
- *WebsiteUrl*: URL do website do usuário
- *Location*: localização
- *AboutMe*: texto sobre o usuário
- *Views*: número de vezes que o perfil do usuário foi visto
- *UpVotes*: número de *upvotes* (votos positivos) que o usuário recebeu
- *DownVotes*: número de *downvotes* (votos negativos) que o usuário recebeu
- *ProfileImageUrl*: URL da imagem do perfil do usuário
- *EmailHash*: hash do e-mail
- *AccountId*: identificador do perfil do usuário na *Stack Exchange Network* (<https://stackexchange.com/>)

Tabela *PostTypes*

- *Id*: identificador do tipo de postagem
- *Type*: nome do tipo de postagem
Valores: 1 = Question; 2 = Answer; 3 = Orphaned tag wiki; 4 = Tag wiki excerpt; 5 = Tag wiki; 6 = Moderator nomination; 7 = “Wiki placeholder” (parece incluir conteúdo auxiliar do site, como a introdução da central de ajuda, a descrição da eleição e as seções de introdução, “Ask” e “Don’t Ask” da página de tour); 8 = Privilege wiki.

Tabela *Posts*

- *Id*: identificador da postagem
- *PostTypeId*: identificador do tipo de postagem (chave estrangeira para *PostTypes*)
- *AcceptedAnswerId* (somente presente se *PostTypeId* = 1 - Question): identificador da postagem escolhida como resposta aceita para a questão (chave estrangeira para *Posts*)
- *ParentId* (somente presente se *PostTypeId* = 2 - Answer): identificador da postagem que a contém (chave estrangeira para *Posts*)
- *CreationDate*: data de criação da postagem

- *Score*: pontuação da postagem (geralmente é não zero somente para postagens que são do tipo *Question*, *Answer* e *Moderator nomination*)
- *ViewCount*: número de visualizações da postagem
- *Body*: texto da postagem em formato HTML
- *OwnerUserId*: identificador do usuário proprietário da postagem (chave estrangeira para *Users*)
- *OwnerDisplayName*: nome de exibição do usuário proprietário
- *LastEditorUserId*: identificador do usuário que fez a última edição da postagem (chave estrangeira para *Users*)
- *LastEditorDisplayName*: nome de exibição do usuário que fez a última edição
- *LastEditDate*: data e horário da última edição feita na postagem
- *Title*: título da postagem
- *Tags*: tags da postagem
- *AnswerCount*: número de respostas de uma postagem do tipo *Answer* (somente presente se *PostTypeId* = 1)
- *CommentCount*: número de comentários recebidos
- *FavoriteCount*: número de votos recebidos
- *ClosedDate*: data de fechamento da postagem
- *CommunityOwnedDate*: data de “absorção” da postagem pela *community wiki* (presente apenas se a postagem foi absorvida)

Tabela *PostLinks*

Em uma postagem, é possível mencionar/referenciar uma outra postagem, criando uma ligação entre elas. Esta tabela armazena dados dessas ligações.

- *Id*: identificação da ligação entre postagens
- *CreationDate*: data de criação da ligação
- *PostId*: identificação da postagem de origem (chave estrangeira para *Posts*)
- *RelatedPostId*: identificação da postagem de destino/relacionada (chave estrangeira para *Posts*)
- *LinkTypeId*: identificação do tipo da ligação (chave estrangeira para *LinkTypes*)

Tabela *LinkTypes*

- *Id*: identificação do tipo de ligação
- *Type*: nome do tipo de ligação
Valores na tabela: 1 = Linked (*PostId* contém um link para *RelatedPostId*); 3 = Duplicate (*PostId* é uma duplicata de *RelatedPostId*)

Tabela *Comments*

- *Id*: identificação do comentário
- *PostId*: identificação da postagem onde o comentário foi feito (chave estrangeira para *Posts*)
- *Score*: pontuação do comentário
- *Text*: texto (corpo) do comentário
- *CreationDate*: data de criação
- *UserId*: identificação do usuário que fez o comentário (chave estrangeira para *Users*)

Tabela *Votes*

- *Id*: identificação do voto
- *PostId*: identificação da postagem que recebeu o voto (chave estrangeira para *Posts*)
- *VoteTypeId*: identificação do tipo de voto (chave estrangeira para *VoteTypes*)
- *UserId*: identificação do usuário que votou (chave estrangeira para *Users*)
- *CreationDate*: data do voto
- *BountyAmount*: valor da recompensa; presente apenas se o tipo do voto for 8 = BountyStart ou 9 = BountyClose (ver mais sobre *bounty* em <https://stackoverflow.com/help/bounty>)

Tabela *VoteTypes*

- *Id*: identificação do tipo de voto
- *Type*: nome do tipo de voto
Exemplos de valores na tabela: 2 = UpMod (voto positivo); 3 = DownMod (voto negativo); 5 = Favorite; 12 = Spam; 13 = InformModerator

Tabela *Badges*

Além de ganhar reputação com suas perguntas e respostas, os usuários recebem *badges* (distintivos) quando são especialmente prestativos. Os *badges* aparecem na página de perfil do usuário e nas suas postagens. Veja mais explicações em: <https://stackoverflow.com/help/badges>.

- *Id*: identificação do *badge*
- *UserId*: identificação do usuário que recebeu o badge (chave estrangeira para *User*)
- *Name*: nome do *badge*
- *Date*: data de atribuição